



A09 論文研讀

AI 語意向量站得住腳嗎？

一篇企業 RAG 回顧，幫我把「技術選擇、評估方法、研究缺口」一次補齊

Retrieval-Augmented Generation (RAG) and LLMs for Enterprise Knowledge Management and Document Automation: A Systematic Literature Review

Karakurt & Akbulut (2026) | Applied Sciences, 16(1), 368 | DOI: 10.3390/app16010368

本研讀聚焦：摘要、引言、背景、研究方法、RQ1-6 與 RQ9、討論、結論

為什麼我要讀這篇

這篇是企業級重裝備，我是個人小工具，但它正好當我的對照面

它 這篇做了什麼

- ▶ 把 63 篇高品質研究系統性整理，回答九個研究問題
- ▶ 對象是企業級 RAG：雲端、FAISS、微調模型
- ▶ 發現語意向量檢索是主流（80.5% 用密集向量）
- ▶ 自己點出評估缺口：真實場景案例只有 13%
- ▶ 自己點出商業影響評估只有 15.9%

我 對我研究的意義

- ▶ 我選 NotebookLM（語意向量）有業界基礎，不是亂選
- ▶ 它的「密集向量 vs 關鍵字」對比，正是我的兩組對照
- ▶ 它缺的「真實場景＋特殊文件」，正是我要補的
- ▶ 它缺的「實務指標」，正是我六項指標的設計理由
- ▶ 它全是企業重裝備，我反問：免費工具能做到幾分？

文獻資訊與公信力

先確認份量，再決定怎麼引用

完整出處 Karakurt, E., & Akbulut, A. (2026). Retrieval-Augmented Generation (RAG) and Large Language Models (LLMs) for Enterprise Knowledge Management and Document Automation: A Systematic Literature Review. **Applied Sciences**, 16(1), 368.

DOI 10.3390/app16010368 | 開放取用 (Open Access)

期刊等級

Applied Sciences | Q2 (SCIE 收錄)

可作正式引用支撐

文獻類型

系統性文獻回顧 SLR | 63 篇原始研究

二手整合，當地圖用

研讀範圍

摘要、引言、2.1–2.4、方法、RQ1–6、
RQ9、討論、結論

RQ7/RQ8 技術細節略

這篇在說什麼：一句話

技術很成熟，但卡在「從實驗室到市場」

實驗室裡 RAG + LLM 技術蓬勃，2020 後爆發成長，密集向量 + GPT 已成標準配方

到市場時 真實場景部署只有 13%、商業影響評估只有 15.9%、即時整合研究不到 15%

這道落差 作者叫它 lab-to-market gap，並提出補洞的策略路線圖

→ 它證明：技術不是問題，「能不能落地、能不能證明價值」才是問題。這正好是我研究的精神。

它怎麼做研究：系統性文獻回顧

三階段、九問題、嚴格篩選到 63 篇




圖 1 規劃→執行→報告 三階段流程

為什麼這套方法值得我學

- ▶ 三階段：規劃、執行、報告，每步都有協定降低偏誤
- ▶ 九個研究問題（RQ1–9）先定好，再轉成檢索字串
- ▶ 六大資料庫檢索，逾 500 篇候選
- ▶ 排除非英文、純摘要、非實證、方法不清的
- ▶ 八題品質評分，低於 10 分（滿分 16）剔除
- ▶ 最後留下 63 篇，雙人獨立編碼確保一致

嚴格篩選的兩張底圖

從五百多篇到 63 篇，品質分數都在 11 分以上




圖 2 各篩選階段後的論文分布




圖 3 入選論文品質分數分布（11-16 分）

我的對照 我做題庫時也要有這種紀律：30-50 題標準化、附要點化評分規準，讓「成效好不好」可被檢核，而不是憑感覺。

整個領域長什麼樣

一張分類圖看完 RAG 的全貌




圖 6 RAG 與 LLM 元件主題分類：學習範式、索引策略、模型骨幹、應用領域

我看的重點 中間「索引策略」分支裡的「密集向量索引」，就是我 NotebookLM 這類工具的技術根；旁邊的 BM25 就是傳統關鍵字搜尋。

技術主流：語意向量站得住腳

RQ3 監督式為主、RQ4 密集向量是標準，這支撐我的工具選擇

80.5%

密集向量檢索是主流

FAISS / Annoy

92.2%

監督式學習主導

標註資料訓練

55%

常再加 BM25 稀疏過濾

語意 + 關鍵字混用

這三個數字，幫我擋掉一個質疑

有人可能問：你為什麼用語意向量、用 NotebookLM，而不是別的？

這篇回顧告訴我：在 63 篇企業級研究裡，密集向量檢索是壓倒性的主流（80.5%），它不是小眾偏方，是業界打過仗的標準做法。我選語意向量工具，是站在這個主流之上。

更巧的是，它發現實務上常把「密集向量 + 關鍵字（BM25）」混用，這也呼應我為什麼要拿這兩種搜尋來正面比較。

評估指標：我的六項指標從哪來

RQ5 整理的 IR 評估體系，就是我研究方法的依據




圖 10 各評估指標類別的採用比例

它的指標 → 我的六項指標

- ▶ 正確率 / 召回率 (81%) → 我的「答案正確率」
- ▶ Recall@K (73%) → 我的「來源命中率」
- ▶ ROUGE/BLEU (44%) → 我的「答案完整度」要點命中
- ▶ 人工評估只有 19% → 我加「查詢時間、查詢次數」補實務
- ▶ 商業影響只有 15.9% → 我聚焦真實查詢任務，補這個洞

驗證方法：真實場景才是稀缺的

RQ6 | 93.6% 靠交叉驗證，真實案例只有 12.7%




圖 11 驗證方法分布

它的稀缺，正是我的切入

93.6% 用 k 折交叉驗證，統計上漂亮，但多在實驗室裡跑

12.7% 才有真實世界案例／實地試驗

關鍵發現 這 12.7% 的實地部署裡，有 80% 都納入了商業影響指標，「真實場景」和「能證明價值」是綁在一起的。

我的研究就是補上這個稀缺：把工具放進真實的知識交接情境去測。

它沒解決的，正是我的位置

RQ9 | 五大挑戰與研究缺口

五大反覆出現的挑戰

- ▶ 幻覺與事實一致性 47.6%
- ▶ 資料隱私與安全 38.1%
- ▶ 延遲與可擴展性 31.7%
- ▶ 領域適應與遷移 23.8%
- ▶ 商業影響難衡量 15.9%

三個缺口，三個我能補的點

- ▶ 評估多用通用語料（MS MARCO、SQuAD）
→ 我用「隱性知識外化文件」這種特殊文件
- ▶ 真實場景案例稀少（12.7%）
→ 我做真實知識交接情境的成效測試
- ▶ 全是企業級重裝備
→ 我問：免費工具能否民主化這套能力

A09 是企業級的對照面，我補的是它的三個缺

理論與技術根

這篇證明語意向量是企業 RAG 主流
（80.5%），

我選 NotebookLM 站在主流之上，不是
亂選

方法論依據

它整理的 IR 評估體系
（Recall@K、ROUGE 等），

是我六項指標的設計來源，我再補實務
指標

貢獻定位

它缺真實場景、特殊文件、實務評估，
我在「隱性知識外化文件、知識交接」
補上

一句話收束： 它用企業級重裝備證明了語意向量的價值，我要證明的是，這份價值，免費工具也構得到。

出處與引用資訊

可直接抄進參考文獻

APA 格式

Karakurt, E., & Akbulut, A. (2026). Retrieval-Augmented Generation (RAG) and Large Language Models (LLMs) for enterprise knowledge management and document automation: A systematic literature review. **Applied Sciences**, **16**(1), 368.

<https://doi.org/10.3390/app16010368>

期刊

Applied Sciences

等級

Q2 (SCIE)

年份卷期

2026, 16(1), 368

類型

系統性回顧 SLR

研讀範圍 涵蓋摘要、第 1 節引言、第 2 節背景（2.1–2.4）、第 3 節方法、第 4 節 RQ1–RQ6 與 RQ9、第 5 節討論、第 6 節結論；RQ7（軟體指標）、RQ8（最佳配置模型細節）與本研究相關性較低，未納入本次研讀。

完整中英對照

逐段中英對照文件，掃碼或點連結看全文

QR 待回填

上傳 Google Drive 後補上

三層備援，現場不怕出狀況

- ▶ 可點擊超連結（簡報播放時直接點）
- ▶ 完整網址文字（連結點不開可手打）
- ▶ QRcode（手機掃，指向同一份文件）

檔案 A09 中英對照 .docx（逐段中英對照、含原文圖表、藍框譯文）

網址（請小 D 上傳 Google Drive 後，把分享連結貼回，我再生成 QR 並回填此頁）